CIFAR-10 CNN 구조 비교 보고서

3 주차 1 차 비교: Baseline 대비 구조 변형 5 종 (bn · dropout · deep · wide · gap)

작성일 2026-10-27 | 평가 기준: validation (테스트셋 미사용)

핵심 요약

- **bn(82.73%)과 wide(82.64%)가 Baseline(80.50%)보다 약 2.2%p 높고**, 이 차이는 시드 표준편차(0.6~0.7%p)보다 큽니다. 둘 사이의 차이(0.09%p)는 구분되지 않습니다.
- **deep(+1.42%p)과 dropout(−0.57%p)은 차이가 시드 표준편차보다 작아 의미 있는 차이라고 보기 어렵습니다.** deep 은 시드별 편차가 커서(1.60%p) 결론을 내릴 수 없습니다.
- **gap 은 −8.40%p 로 분명히 낮지만**, 파라미터가 1/6(94,538 개)로 줄어 구조 효과와 크기 효과를 분리할 수 없습니다.
- **20 epoch 고정 조건은 수렴이 느린 모델(dropout, deep, gap)에 불리했을 가능성이 큽니다.** 모든 모델이 20 epoch 에서도 여전히 오르는 중이며, 이는 수렴 후 비교가 아닙니다.
- 클래스별로는 어려운 클래스(cat, dog, bird)에서 개선이 두드러지나, **대부분 시드 표준편차 안**입니다.

1. 실험 조건

- **모델:** baseline(Conv-ReLU-Pool×3 + FC×2, 620,362 개)과, 이 모델과 한 가지씩만 다른 5 종 — bn(Conv 뒤 BatchNorm), dropout(FC 사이 Dropout 0.5), deep(블록당 Conv 2 개), wide(채널 2 배), gap(GAP + FC 1 개).
- **반복:** 6 개 모델 × 시드 3 개(42, 1, 2) = 18 개 실험. 시드는 가중치 초기화·셔플·증강에만 영향을 주고 train/val 분할은 고정입니다.
- **학습 설정(모두 동일):** SGD(lr 0.01, momentum 0.9, weight decay 5e-4), batch 128, 20 epoch, 증강 ON(랜덤 크롭 + 좌우반전), **학습률 스케줄러 없음**. device 는 18 개 모두 cuda.
- **데이터:** train 45,000 / val 5,000(클래스당 500 장). 모델 선택과 비교는 val 만 사용했고 **테스트셋은 사용하지 않았습니다.**
- **통계:** ± 값은 시드 3 개의 표본 표준편차(ddof=1)입니다. 시드가 3 개뿐이라 표준편차 자체가 불안정합니다.

2. 결과 요약

모델	파라미터	best val acc (%)	마지막 5 epoch 평균 (%)	best epoch	train−val (%p)	sec/epoch (중앙값)	Baseline 대비 (%p)	표준편차 대비
bn	620,586	82.73 ± 0.73	81.41 ± 0.37	19.3 ± 1.2	0.72 ± 0.93	7.3	2.23 ± 0.97	큼
wide	1,422,218	82.64 ± 0.58	81.47 ± 0.22	20.0 ± 0.0	1.27 ± 0.47	8.0	2.14 ± 0.86	큼
deep	814,122	81.92 ± 1.60	80.74 ± 1.13	19.3 ± 0.6	1.45 ± 1.45	8.1	1.42 ± 1.72	작음
baseline	620,362	80.50 ± 0.64	79.80 ± 0.84	18.3 ± 1.5	1.00 ± 0.67	6.9	—	—
dropout	620,362	79.93 ± 0.26	78.89 ± 0.24	18.7 ± 1.2	-1.53 ± 1.26	7.0	-0.57 ± 0.69	작음
gap	94,538	72.10 ± 0.38	70.47 ± 0.14	19.3 ± 1.2	0.08 ± 1.15	6.9	-8.40 ± 0.74	큼

best val acc 내림차순. “표준편차 대비”는 Baseline 과의 평균 차이가 두 모델 시드 표준편차 중 큰 값보다 큰지를 뜻합니다(음영 = 작음 → 의미 있는 차이라고 보기 어렵다). Baseline 대비 ± 값은 두 모델의 표준편차를 독립으로 가정해 합성했습니다.

읽을 때 주의: (1) best val acc 는 20 개 epoch 중 최댓값이라 약간 낙관적이므로 마지막 5 epoch 평균을 함께 보세요. (2) train−val 은 증강이 켜진 학습 모드(Dropout/BN 활성)에서 측정한 train acc 기준이라 과적합의 근사치일 뿐이며 음수도 나옵니다. (3) 소요 시간은 week3_summary.csv 기준이며 참고용입니다. 이후 받은 history.csv 의 epoch_time_sec 와 17 개 실험에서 값이 달라(최대 3.8 초, 정확도·손실은 동일) 실행 환경에 따라 달라지는 값으로 보아야 합니다. baseline seed42 는 두 기록 모두 epoch 당 17.3 초로 다른 시드보다 깁니다.

3. 학습 곡선과 비교 그림

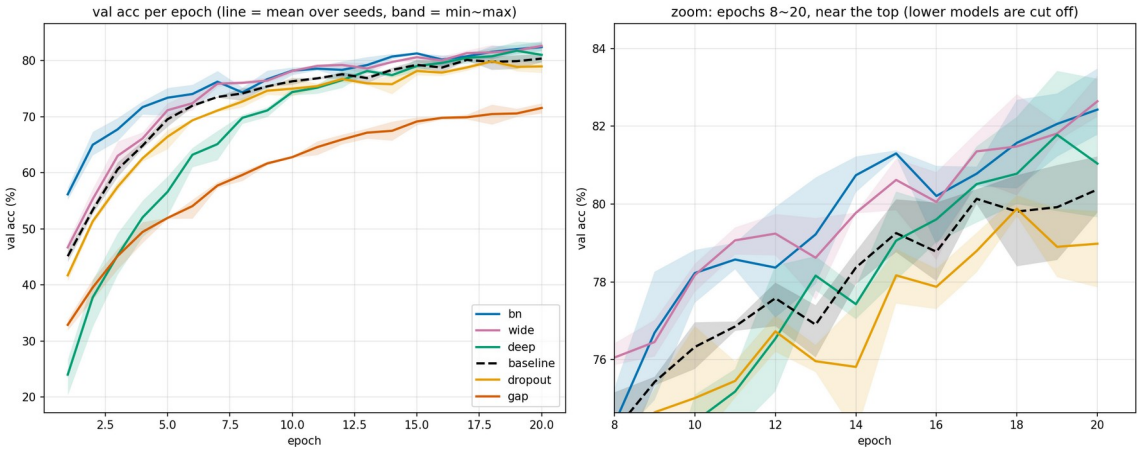


그림 1. 모델별 val acc 학습 곡선 (선 = 시드 평균, 음영 = 시드 최소~최대). 오른쪽은 상위 구간 확대.

bn 과 wide 는 초반부터 빠르게 올라 약 7 epoch 에 75%에 도달하고, baseline·dropout 은 9~10 epoch, deep 은 11 epoch 가 걸립니다. gap 은 20 epoch 까지도 75%에 닿지 못합니다. 모든 모델의 곡선이 20 epoch 에서도 우상향 중입니다.

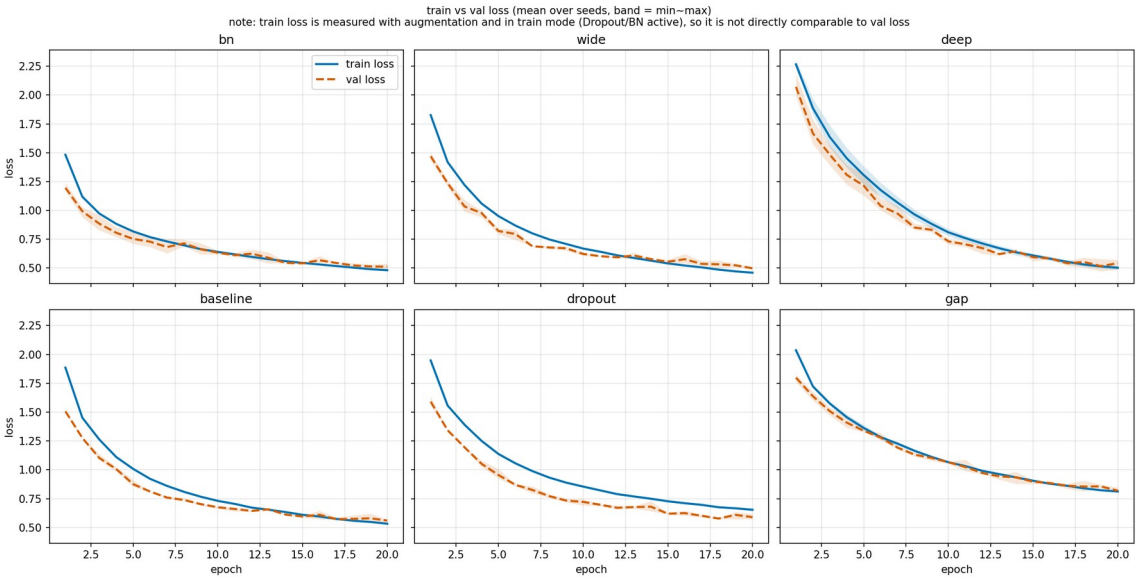


그림 2. 모델별 train/val loss (시드 평균, 음영 = 최소~최대). train loss 는 증강·학습 모드 기준이라 val loss 와 직접 비교는 제한적.

val loss 가 train loss 보다 낮거나 비슷해 뚜렷한 과적합 신호는 없습니다. dropout 은 train loss 가 가장 높아(0.654) 아직 충분히 학습되지 않은 상태로 보입니다.

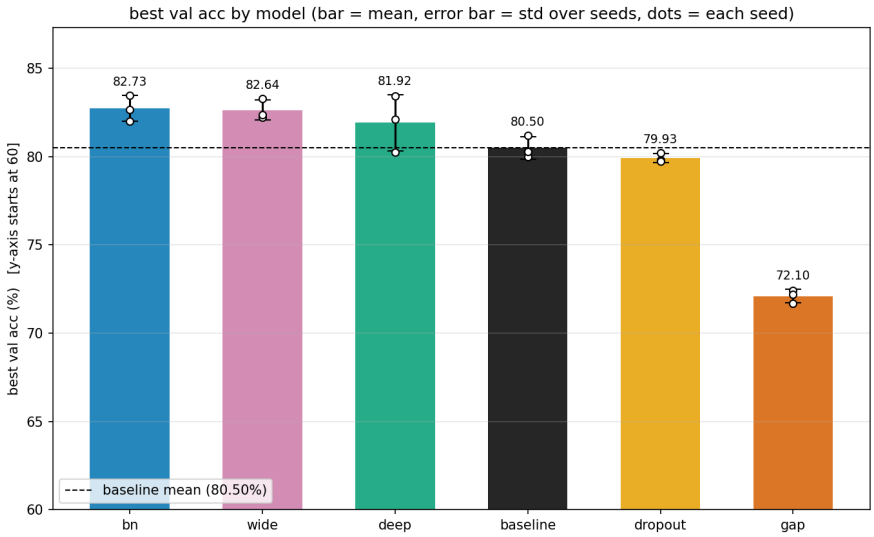


그림 3. best val acc (막대 = 평균, 오차막대 = 시드 표준편차, 흰 점 = 각 시드, 점선 = Baseline 평균). y 축은 60%에서 시작.

deep 의 오차막대는 Baseline 기준선까지 걸치고, dropout 은 기준선 아래에 있습니다. y 축이 60%에서 시작하므로 막대 길이로 상대 크기를 비교하면 과장됩니다.

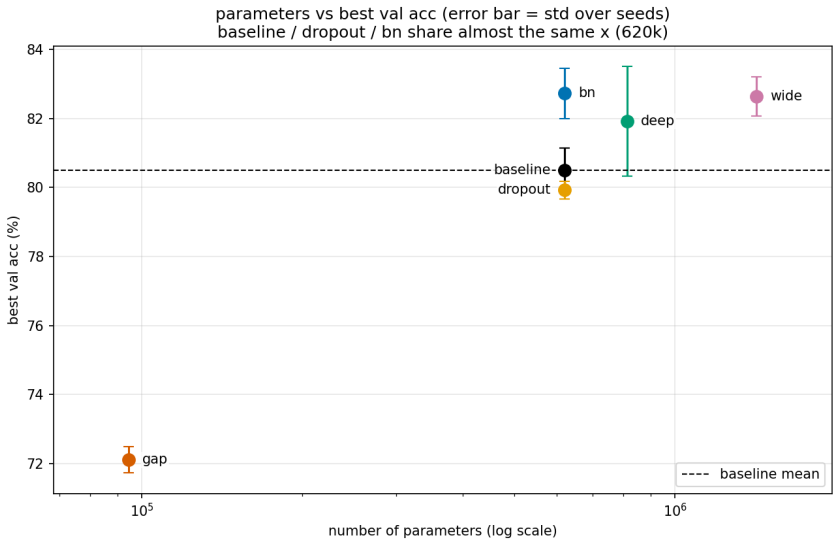


그림 4. 파라미터 수(로그 축) vs best val acc (오차막대 = 시드 표준편차).

파라미터 수와 정확도가 비례하지 않습니다. bn 은 파라미터가 224 개(0.04%) 늘었을 뿐인데 약 +2.2%p, wide 는 2.3 배인데 비슷한 +2.1%p 입니다. baseline·dropout·bn 은 파라미터 수가 거의 같아 한 세로줄에 겹칩니다.

4. 상위 모델의 클래스별 val 정확도

best val acc 상위 3 개 모델(bn, wide, deep)과 baseline 을 `evaluate.py --run`(val, best epoch 체크포인트)으로 평가해 합쳤습니다. 클래스별 평균(macro)이 history 의 best val acc 와 일치함을 확인했습니다. 평가는 CPU 에서 수행했고 (학습은 cuda) 두 값은 소수점 둘째 자리까지 같았습니다.

클래스	baseline	bn	wide	deep
airplane	81.60 ± 0.40	82.93 ± 4.96	85.80 ± 1.04	86.73 ± 2.52
automobile	93.07 ± 0.31	93.60 ± 1.22	90.27 ± 3.30	92.27 ± 1.94
bird	72.67 ± 3.06	75.33 ± 4.30	76.73 ± 3.83	71.87 ± 3.29
cat	56.13 ± 13.45	63.67 ± 7.51	68.53 ± 3.00	65.80 ± 11.52
deer	81.27 ± 1.67	84.60 ± 3.29	81.27 ± 2.91	83.33 ± 3.44
dog	71.40 ± 7.48	76.27 ± 4.62	74.00 ± 1.22	71.40 ± 9.68
frog	86.13 ± 4.50	87.40 ± 3.03	85.47 ± 2.05	83.80 ± 5.26
horse	85.47 ± 3.51	84.80 ± 4.95	82.67 ± 4.28	86.47 ± 6.52
ship	89.13 ± 2.34	89.67 ± 1.81	90.87 ± 0.23	90.20 ± 3.00
truck	88.13 ± 3.72	89.00 ± 5.21	90.80 ± 3.02	87.33 ± 6.93
macro_avg	80.50	82.73	82.64	81.92

표 3. val 클래스별 정확도 (%), 시드 3 개 평균 ± 표준편차. macro_avg 는 클래스 평균(= 전체 val acc).

클래스	bn − baseline	wide − baseline	deep − baseline
airplane	+1.3	+4.2 *	+5.1 *
automobile	+0.5	-2.8	-0.8
bird	+2.7	+4.1 *	-0.8
cat	+7.5	+12.4	+9.7
deer	+3.3 *	+0.0	+2.1
dog	+4.9	+2.6	-0.0
frog	+1.3	-0.7	-2.3
horse	-0.7	-2.8	+1.0
ship	+0.5	+1.7	+1.1
truck	+0.9	+2.7	-0.8

*표 4. Baseline 대비 클래스별 정확도 차이(%p). * 표시 = 차이가 두 모델 시드 표준편차 중 큰 값보다 큼(음영). 표시가 없으면 의미 있는 차이라고 보기 어렵습니다.*

5. 해석

5.1 모델 간 차이는 의미 있는가

- **bn, wide:** Baseline 대비 +2.23 ± 0.97, +2.14 ± 0.86%p 로 시드 표준편차(0.6~0.7%p)보다 큽니다. 다만 시드가 3 개뿐이어서 이 기준이 통계적 유의성을 보장하지는 않습니다. 마지막 5 epoch 평균으로 봐도 순위가 같습니다(81.41, 81.47 vs 79.80).
- **bn vs wide:** 차이 0.09%p 는 표준편차보다 훨씬 작아 의미 있는 차이라고 보기 어렵습니다. 같은 정확도를 +224 개 파라미터(bn)와 +80 만 개 파라미터(wide)로 얻었다는 점이 차이입니다.
- **deep:** 평균 +1.42%p 지만 시드 표준편차가 1.60%p 로 더 큽니다. 시드별 best 가 80.24, 82.10, 83.42 로 갈려 의미 있는 차이라고 보기 어렵습니다.
- **dropout:** −0.57%p 로 표준편차(0.26~0.64%p)와 비슷한 수준이라 의미 있는 차이라고 보기 어렵습니다. 효과가 없다기보다 이 조건에서는 판단할 수 없습니다(5.2 참고).
- **gap:** −8.40%p 는 표준편차보다 훨씬 큽니다. 그러나 분류부 구조를 바꾼 것과 파라미터를 1/6 로 줄인 것이 함께 일어나 원인을 하나로 단정할 수 없습니다.

5.2 20 epoch 고정 조건의 영향

모델	val acc ep10	ep15	ep20	ep10→20 (%p)	마지막 10 epoch 기울기 (%p/ep)	train loss ep20	val loss ep20	75% 도달 epoch
bn	78.2	81.3	82.4	+4.2	0.43	0.482	0.512	7
wide	78.2	80.6	82.6	+4.5	0.42	0.460	0.499	7
deep	74.4	79.1	81.0	+6.6	0.68	0.503	0.542	11
baseline	76.3	79.3	80.4	+4.0	0.41	0.533	0.560	9
dropout	75.0	78.2	79.0	+4.0	0.46	0.654	0.590	10
gap	62.8	69.2	71.6	+8.8	0.73	0.812	0.819	미도달

표 5. 20 epoch 시점의 수렴 상태 (시드 평균). 기울기는 11~20 epoch val acc 의 선형 회귀 기울기.

- **모든 모델이 아직 수렴하지 않았습니다.** 마지막 10 epoch 동안 epoch 당 +0.4~0.7%p 씩 오르는 중이고, 학습률이 고정(lr 0.01)이라 epoch 간 val acc 가 약 1%p 씩 출렁입니다.
- **dropout 에 불리했을 가능성이 큽니다.** 20 epoch 시점의 train loss(0.654)가 val loss(0.590)보다 높고 baseline(0.533)과도 격차가 큽니다. 과적합이 생기기 전 단계에서 규제만 받고 있어, 규제가 이득을 낼 구간에 도달하지 못했을 수 있습니다. 따라서 "dropout 은 효과 없음"이 아니라 이 조건에서는 판단 불가가 맞습니다.
- **gap 과 deep 도 불리했을 가능성이 있습니다.** gap(+0.73%p/epoch)과 deep(+0.68%p/epoch)이 가장 가파르게 오르는 중입니다. gap 은 75%에도 닿지 못했습니다.
- **bn 과 wide 는 유리한 조건이었습니다.** 약 7 epoch 에 75%에 도달해 20 epoch 고정에서 가장 많이 이득을 봤습니다. 이 우위의 일부는 "더 높은 최종 성능"이 아니라 "더 빠른 수렴"일 수 있습니다.

5.3 클래스별 결과

- 개선은 어려운 클래스에 집중됩니다. baseline 의 cat 정확도는 56.1%로 가장 낮고, bn +7.5, wide +12.4, deep +9.7%p 로 가장 크게 오릅니다. dog 와 bird 도 bn 과 wide 에서 올랐습니다.
- **그러나 대부분 의미 있는 차이라고 보기 어렵습니다.** 표준편차보다 큰 차이는 airplane(wide +4.2, deep +5.1), bird(wide +4.1), deer(bn +3.3) 네 건뿐입니다. cat 은 baseline 시드 표준편차가 13.5%p 라 큰 향상도 시드 편차 안에 들어갑니다.
- automobile, ship, truck 같은 쉬운 클래스는 모델 간 차이가 작습니다(wide 의 automobile −2.8%p 도 표준편차 안). 전체 향상은 대부분 어려운 클래스에서 나옵니다.

6. 4 주차 2 차 비교: 조합해 볼 구조 요소 후보

아래는 3 주차 단독 결과에서 나온 가설이며, 4 주차에서 검증해야 합니다.

- ① **bn + wide (우선순위 높음).** 둘 다 단독으로 약 +2%p 이고 수렴이 빠릅니다. 같은 이득을 중복으로 보는 것일 수 있어 합쳐서 +4%p 가 된다는 보장은 없습니다. 조합이 단독보다 나은지가 핵심 질문입니다. 파라미터 효율은 bn 이 훨씬 좋으므로 wide 를 줄인 중간 폭도 함께 보면 좋습니다.
- ② **bn + deep.** deep 은 평균이 올랐지만 수렴이 느리고 시드 편차가 큽니다(1.60%p). bn 은 수렴을 앞당기고 편차를 줄였으니(0.73%p), bn 이 deep 의 불안정성을 해소하는지 볼 만합니다. deep 이 시드 편차 이상의 이득이 있는지 가릴 가장 좋은 실험입니다.
- ③ **dropout 은 조건을 바꿔 재평가.** 이번 결과로는 후보에서 뺄 근거가 약합니다. 학습이 길어지거나 bn 과 함께일 때 규제 효과가 나타나는지 확인합니다. 단독 20 epoch 결과만으로 제외하지 않는 것이 좋습니다.
- ④ **gap 은 단독 후보에서 제외.** 성능 손실이 크고 원인이 분리되지 않습니다. 쓰려면 채널 수를 키워 파라미터를 맞춘 gap 을 따로 만들어 크기 효과와 구조 효과를 나눠야 합니다.

실험 설계 제안

- 에폭 수와 학습률 스케줄은 조합 실험과 **별도의 변수**로 다루세요. 20 epoch 고정이 수렴 속도 차이를 성능 차이로 보이게 만들 수 있습니다.
- 시드를 3 개 이상 유지하고, 비교는 best 단독이 아니라 마지막 5 epoch 평균을 함께 보고하세요.
- cat, dog, bird 세 클래스를 따로 추적해 조합의 이득이 어려운 클래스에서 유지되는지 확인하세요.

7. 한계와 주의 사항

- 시드 3 개로는 표준편차 추정이 불안정하고, “표준편차보다 큼”은 통계적 유의성이 아닙니다.
- best val acc 는 최댓값이라 낙관 편향이 있습니다. 같은 val 5,000 장으로 모델 선택과 비교를 모두 했으므로 최종 성능 추정으로 쓰면 안 됩니다. 테스트셋 평가는 6 주차에서 합니다.
- train acc 는 증강·학습 모드 기준이라 과적합 정도(train−val)는 근사치입니다.
- 소요 시간은 신뢰도가 낮습니다. baseline seed42 가 이상치(17.3 초)이고, 같은 실험의 history.csv 시간 값이 기록본에 따라 달라졌습니다(최대 3.8 초). 시간 비교는 중앙값을 쓰고 참고용으로만 보세요.
- 클래스별 평가는 CPU 에서 수행했고 학습은 cuda 였습니다. macro 정확도가 history 와 일치해 영향은 확인되지 않았습니다.
- 클래스별 비교는 시드 3 개, 클래스당 val 500 장 기준이라 클래스 단위 차이는 표본이 작습니다.

8. 재현 방법

프로젝트 루트에서 실행합니다(torch 필요). 결과는 results/week3_summary.csv, results/week3_per_class_val_acc.csv, figures/week3/에 저장됩니다.

```
python compare_results.py             # 표 + 그림 + 상위 3 개 모델 클래스별 정확도
python compare_results.py --no-eval   # evaluate.py 호출 없이 기존 CSV 만 사용
```